自然语言处理作业一实验报告

姓名：强博　学号：2313825

2026 年 10 月 11 日

1　实验目的

本实验旨在理解不同文本表示方法的基本原理，掌握新闻分类的标准实验流程，使用逻辑回归完成基于词袋和词向量的分类，并通过微调 BERT 了解预训练语言模型的使用方式。实验统一比较 Accuracy 和 Macro-F1，分析模型性能差异及类别不均衡的影响。

2　数据集与实验设置

2.1　数据集

NYT 数据集包含新闻文本 text 和类别标签 label，共 11,519 条样本，其中 business 1,429 条、politics 1,451 条、sports 8,639 条。AG News 数据集用于训练另一组 Word2Vec 词向量。NYT 按照 80%/10%/10% 分层划分，随机种子设置为 42，所有分类实验使用相同划分。

表 1: NYT 数据集划分

数据集	数量	比例
训练集	9,215	80%
验证集	1,152	10%
测试集	1,152	10%

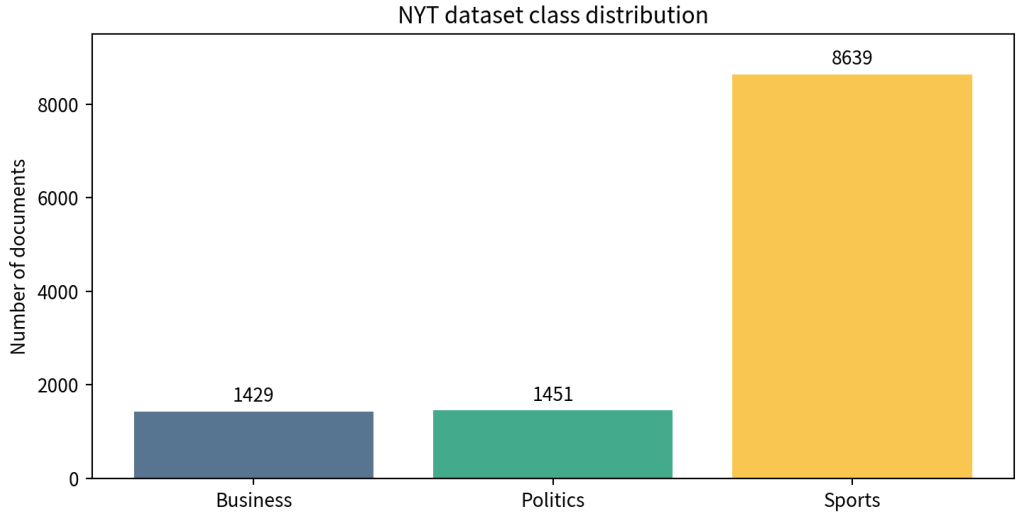


图 1: NYT 数据集类别分布

体育类样本明显多于其他两类，故不能只用总体准确率衡量模型，应同时考察 Macro-F1。

2.2 评价指标

准确率定义为正确预测的样本数占总样本数的比例：

$$\text{Accuracy} = \frac{N_{\text{correct}}}{N_{\text{total}}}. \tag{1}$$

对类别 i，精确率、召回率及 F1 分别为

$$P_i = \frac{TP_i}{TP_i + FP_i}, \quad R_i = \frac{TP_i}{TP_i + FN_i}, \quad F1_i = \frac{2P_iR_i}{P_i + R_i}. \tag{2}$$

$$\text{Macro-F1} = \frac{1}{C}\sum_{i=1}^{C} F1_i, \qquad C = 3. \tag{3}$$

Macro-F1 为每个类别赋予相同权重，能更全面地反映不均衡数据上的分类能力。

3 Task 1：Bag of Words 文本分类

3.1 方法与实现

词袋模型将文档映射到基于训练集词表的稀疏向量空间。二值词袋（Binary BoW）只记录单词是否出现：

$$x_i = \begin{cases} 1, & w_i \text{ 在文档中出现}, \\ 0, & \text{否则}. \end{cases} \tag{4}$$

词频词袋（Word Frequency BoW）则记录单词出现次数 c_i，得到 $\mathbf{x} = (c_1, \ldots, c_{|V|})$。两种表示均使用 Logistic Regression 训练分类器；词表只在训练集上构建，再应用于验证集和测试集，以避免数据泄漏。

3.2 实验结果与分析

表 2: Task 1 验证集与测试集结果

方法	Val Acc	Val F1	Test Acc	Test F1
Binary BoW	0.9809	0.9551	0.9887	0.9718
Word Frequency BoW	**0.9835**	**0.9626**	**0.9896**	**0.9743**

两种模型均取得较高性能，说明新闻类别与词汇分布有较强关联。词频词袋的测试集 Accuracy 和 Macro-F1 分别为 98.96% 与 97.43%，略高于二值词袋，表明词语重复次数可提供额外信息。两种模型训练集准确率均达到 100%，但不能仅凭此断言存在严重过拟合；其测试集表现仍较好。

4 Task 2：Word Embedding 文本分类

4.1 方法与实现

词向量将单词映射到低维连续空间。本任务统一采用 100 维词向量，并对文档中有有效向量的单词取平均：

$$\mathbf{e}(d) = \frac{1}{n} \sum_{i=1}^{n} \mathbf{e}(w_i). \tag{5}$$

再以平均文档向量训练 Logistic Regression。比较三种表示：（1）公开预训练的 GloVe 6B 100d；（2）基于 AG News 语料训练的 Word2Vec；（3）基于 NYT 语料训练的 Word2Vec。

4.2 实验结果与分析

表 3: Task 2 验证集与测试集结果

方法	Val Acc	Val F1	Test Acc	Test F1
GloVe 100d	0.9774	0.9500	**0.9852**	**0.9646**
Word2Vec (AG News)	0.9653	0.9248	0.9766	0.9416
Word2Vec (NYT)	0.9679	0.9293	0.9818	0.9542

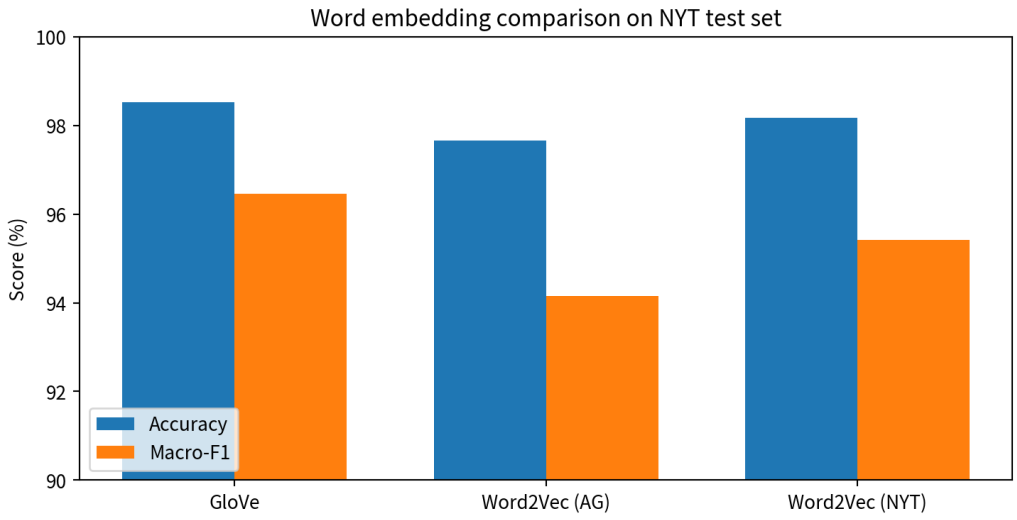


图 2: 三种词向量方案的测试集表现

预训练 GloVe 表现最好，可能得益于更充分的预训练语料和词汇共现信息。NYT Word2Vec 优于 AG News Word2Vec，提示训练语料与目标任务的领域匹配程度可能影响分类效果；但由于训练语料规模等因素未被严格控制，不能将差异完全归因于领域一致性。平均池化无法保留词序和复杂上下文，也是该类方法的局限。

5 Task 3：BERT 微调分类

5.1 模型与训练设置

使用 `google-bert/bert-base-uncased`，最大序列长度设为 64，训练 3 epochs。BERT 利用双向 Transformer 编码器产生上下文相关的表示，并通过分类头预测新闻类别。

表 4: BERT 主要训练配置

参数	设置
预训练模型	bert-base-uncased
最大序列长度	64
训练轮数	3
学习率	2×10^{-5}
训练 batch size	16
评估 batch size	32
随机种子	42

5.2 验证集结果

表 5: BERT 每轮验证集性能

Epoch	Accuracy	Macro-F1
1	0.9688	0.9315
2	**0.9766**	**0.9524**
3	0.9757	0.9498

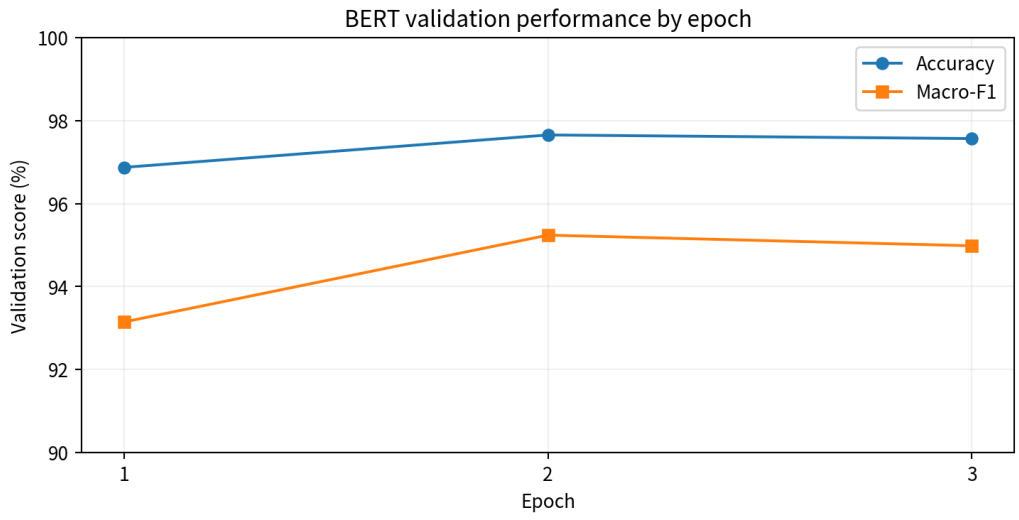


图 3: BERT 三轮训练的验证集指标变化

第 2 轮的验证集 Accuracy 和 Macro-F1 均最高，第 3 轮略有下降。这说明继续训练并未稳定提升验证集性能，后续可尝试依据验证集指标选择最佳检查点。

5.3 测试集结果

BERT 最终测试集 Accuracy 为 0.9818，Macro-F1 为 0.9591。各类别结果如下：

表 6: BERT 测试集分类报告

类别	Precision	Recall	F1	Support
business	0.9200	0.9650	0.9420	143
politics	0.9638	0.9172	0.9399	145
sports	0.9954	0.9954	0.9954	864

体育类 F1 最高，而商业和政治类相对较低。由于类别不均衡，仅用 Accuracy 可能掩盖少数类别的错误，因此 Macro-F1 具有重要意义。

6 综合对比与讨论

表 7: 六种方法在 NYT 测试集上的结果

方法	Accuracy	Macro-F1
Binary BoW	0.9887	0.9718
Word Frequency BoW	**0.9896**	**0.9743**
GloVe 100d	0.9852	0.9646
Word2Vec (AG News)	0.9766	0.9416
Word2Vec (NYT)	0.9818	0.9542
BERT	0.9818	0.9591

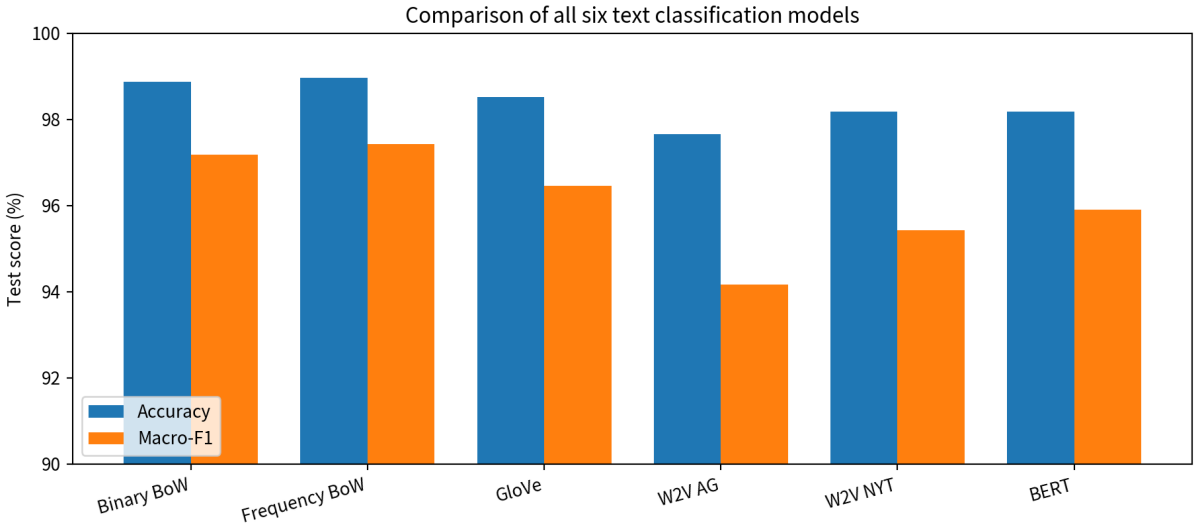


图 4: 六种分类方法的测试集性能对比（纵轴从 90% 起）

六种方法均取得超过 97% 的测试集 Accuracy。词频词袋结合逻辑回归整体表现最佳，表明当前数据集可能存在较强的词汇级类别区分信号。GloVe 在词向量方法中最好，说明大规模预训练表示具有价值。BERT 虽具备上下文建模能力，但未超越词袋模型，可能与任务特征、64-token 截断限制及微调超参数有关；这些原因尚需额外消融实验验证。

值得注意的是，BERT 与 NYT Word2Vec 的 Accuracy 相同，但 Macro-F1 更高，说明相同总体准确率不代表各类别上的表现一致。对于当前体育类别占比较高的数据集，应结合两项指标评价模型。

本实验也存在局限：Task 1 实际完成了二值与词频两种词袋表示；Word2Vec 对比没有严格控制语料规模；BERT 未系统搜索学习率、序列长度与最佳检查点选择策略。后续可进一步开展对照实验。

7 结论

本实验完成了词袋、词向量与 BERT 三类文本分类方法的实现和比较。词频词袋在 NYT 测试集上获得最高 Accuracy（98.96%）和 Macro-F1（97.43%）；预训练 GloVe 优于两种自行训练的 Word2Vec；BERT 获得 98.18% 的 Accuracy 和 95.91% 的 Macro-F1。实验说明，模型复杂度与最终分类效果并不必然正相关，应结合数据特点、训练资源与评价指标选择适合的文本表示方法。

参考文献

[1] Mikolov, T., et al. Efficient Estimation of Word Representations in Vector Space. 2013.

[2] Pennington, J., Socher, R., Manning, C. D. GloVe: Global Vectors for Word Representation. EMNLP, 2014.

[3] Devlin, J., et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. NAACL, 2019.

[4] Pedregosa, F., et al. Scikit-learn: Machine Learning in Python. JMLR, 2011.